

Velocidad de convergencia de los métodos de Jacobi, Seidel y Descenso profundo sobre matrices de prueba de Higham

Raúl Cano-Villegas

Universidad Michoacana de San Nicolás de Hidalgo, Facultad de Ciencias Físico-Matemáticas, 58040 Morelia, Mich., México

Profesor: Francisco Dominguez Mota ■ Correspondencia: 2405099g@umich.mx

Resumen

Se estudia la velocidad de convergencia de los métodos de Jacobi, Seidel y descenso profundo sobre las seis matrices de prueba de Higham de la Tarea 1, con $\mathbf{b} = A\mathbf{1}_n$ para conocer la solución exacta. La tasa teórica se obtiene del radio espectral $\rho(B)$ de la matriz de iteración (Jacobi y Seidel) y de la cota $(\kappa - 1)/(\kappa + 1)$ (descenso profundo), y se compara con la tasa medida en las iteraciones. En Jacobi y Seidel ambas coinciden: con al menos 100 iteraciones la diferencia relativa es menor que 8×10^{-6} . Jacobi diverge en `cauchy`, `hilb` y `chebvand`, y en `moler` con $n \geq 4$; Seidel converge en las tres matrices simétricas definidas positivas, pero $\rho \rightarrow 1$ al crecer κ y las iteraciones se disparan (en `hilb`, de 717 a 94881 para $n = 3, 4, 5$); en `chebvand` ningún método converge. En `kahan`, $\rho = 0$ pero el error llega a crecer 5790 veces antes de caer. Detenerse con residuo $\leq 10^{-9}$ deja un error cercano a $\text{cond}(A) \cdot 10^{-9}$, hasta 10^8 veces mayor que el del método directo. Para estas matrices, los métodos directos de la Tarea 1 son preferibles.

Palabras clave: métodos iterativos, Jacobi, Gauss–Seidel, descenso profundo, radio espectral, velocidad de convergencia.

1. INTRODUCCIÓN Y OBJETIVO

En la Tarea 2 [Cano-Villegas, 2026] se resolvieron sistemas lineales $A\mathbf{x} = \mathbf{b}$ con métodos directos (Chelosky, LU con pivoteo parcial y sustitución hacia atrás) sobre seis matrices mal condicionadas de la colección de Highman [Higham, 1991]. Un método iterativo, en cambio, no factoriza A , sino que parte de una aproximación inicial $\mathbf{x}_0$ y construye una sucesión $\mathbf{x}_k$ que se acerca a la solución. Su utilidad depende de si converge y de qué tan rápido lo hace, y esa rapidez se le llama *velocidad de convergencia*.

En este trabajo se estudian tres métodos: Jacobi, Seidel y descenso profundo. Los dos primeros son estacionarios y su velocidad la determina el radio espectro de su matriz de iteración, por otro lado, el tercero requiere que A sea simétrica definida positiva y su velocidad se acota con el número de condición $\kappa = \text{cond}_2(A)$. Esto conecta con el reporte de la Tarea 1 [Cano-Villegas, 2026], el mal condicionamiento que limitó la exactitud de los métodos directos aquí limita la rapidez de los iterativos. Además, no todos los métodos están definidos o convergen para todas las matrices, por lo que parte del trabajo consiste en determinar, para cada matriz, cuándo cada método aplica,

converge o diverge.

Tenemos dos objetivos:

- 1) Encontrar la velocidad de convergencia de los métodos de Jacobi, Seidel y Descenso profundo, de forma teórica y de forma empírica;
- 2) Verificar los resultados con los problemas de la Tarea 1, es decir, con las matrices **cauchy**, **chebvand**, **forsythe**, **hilb**, **kahan** y **moler**, y comparar con la solución directa obtenida entonces.

2. FUNDAMENTO TEÓRICO

2.1 Velocidad de convergencia

Sea $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}$ el error de la iteración k . Un método converge *linealmente* con razón $\rho < 1$ si

$$\|\mathbf{e}_{k+1}\| \approx \rho \|\mathbf{e}_k\|, \quad \text{de modo que} \quad \|\mathbf{e}_k\| \approx \rho^k \|\mathbf{e}_0\|. \quad (1)$$

La *velocidad* se mide con ρ (cuanto menor, más rápido) o, de forma equivalente, con el número de dígitos decimales que se ganan por iteración, $-\log_{10} \rho$. Para reducir el error en un factor ε hace falta, aproximadamente,

$$k \approx \frac{\ln \varepsilon}{\ln \rho}. \quad (2)$$

iteraciones. Esta estimación se compara más adelante con las iteraciones realmente necesarias.

2.2 Métodos estacionarios: Jacobi y Seidel

Se descompone $A = D + L + U$, con D la diagonal, L la parte estrictamente triangular inferior y U la estrictamente triangular superior. Ambos métodos tienen la forma $\mathbf{x}_{k+1} = B \mathbf{x}_k + \mathbf{c}$ y por lo tanto $\mathbf{e}_{k+1} = B \mathbf{e}_k$. Las matrices de iteración son

$$B_J = -D^{-1}(L + U) \quad (\text{Jacobi}), \quad (3)$$

$$B_{GS} = -(D + L)^{-1}U \quad (\text{Seidel}). \quad (4)$$

El método converge para todo $\mathbf{x}_0$ si y solo si $\rho(B) < 1$, donde $\rho(B)$ es el radio espectral (máximo módulo de los valores propios), y la razón asintótica de Ec. (1) es precisamente

$$\rho = \rho(B) = \max_i |\lambda_i(B)|. \quad (5)$$

Además, $\rho(B) < 1$ se garantiza, entre otros casos, si A es estrictamente diagonal dominante (Jacobi y Seidel) o si A es simétrica definida positiva (Seidel). Jacobi requiere $a_{ii} \neq 0$ para todo i .

2.3 Descenso profundo

Para A simétrica definida positiva, resolver $A\mathbf{x} = \mathbf{b}$ equivale a minimizar $\phi(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T A \mathbf{x} - \mathbf{b}^T \mathbf{x}$. En cada paso se avanza en la dirección del residuo $\mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k$ con paso óptimo:

$$\alpha_k = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{r}_k^T A \mathbf{r}_k}, \quad \mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{r}_k. \quad (6)$$

La convergencia se mide en la norma de la energía $\|\mathbf{e}\|_A = \sqrt{\mathbf{e}^T A \mathbf{e}}$:

$$\frac{\|\mathbf{e}_{k+1}\|_A}{\|\mathbf{e}_k\|_A} \leq \frac{\kappa - 1}{\kappa + 1}, \quad \kappa = \text{cond}_2(A) = \frac{\lambda_{\max}(A)}{\lambda_{\min}(A)}. \quad (7)$$

Aquí $\rho_{\text{DP}} = (\kappa - 1)/(\kappa + 1)$ es una *cota* de la razón, no un radio espectral. Cuando κ es grande, $\rho_{\text{DP}} \approx 1 - 2/\kappa$ y se necesitan del orden de κ iteraciones.

2.4 Tasa empírica

Para comparar con la teoría se guardan, en cada iteración, el residuo relativo $\|\mathbf{r}_k\|/\|\mathbf{b}\|$ y el error relativo $\|\mathbf{x}_k - \mathbf{x}\|/\|\mathbf{x}\|$. Como en la Tarea 1 la solución exacta es el vector de unos, se puede medir el error real. Con ello se estiman dos tasas:

$$\hat{\rho}_{\text{geom}} = \left(\frac{\|\mathbf{r}_k\|}{\|\mathbf{r}_0\|} \right)^{1/k}, \quad (8)$$

$$\hat{\rho}_{\text{ajuste}} = \exp(m), \quad m = \text{pendiente del ajuste lineal de } \ln \|\mathbf{e}_j\| \text{ contra } j. \quad (9)$$

La primera es el promedio de toda la corrida, incluido el transitorio inicial. La segunda se calcula solo sobre la segunda mitad de las iteraciones, donde ya domina el comportamiento asintótico.

3. MATRICES Y APLICABILIDAD

Se usan las mismas seis matrices de la Tarea 1 [Cano-Villegas, 2026] cuyas definiciones y parámetros por defecto están en ese reporte, y el mismo lado derecho $\mathbf{b} = A \mathbf{1}_n$. La estructura de cada matriz ya indica que método tiene sentido. La Tabla 1 lo resume.

Tabla 1. Aplicabilidad esperada de cada método según la estructura de la matriz.

Matriz	Jacobi	Seidel	Descenso profundo
cauchy	Depende de ρ_J	Converge (SPD)	Aplica (SPD)
chebvand	Depende de ρ_J	Depende de ρ_{GS}	No aplica (no simétrica)
forsythe	No definido ($a_{ii} = 0$)	No definido ($a_{ii} = 0$)	No aplica (no simétrica)
forsythe con permutación	Definido (PA diagonal)	Definido (PA diagonal)	Aplica (PA es SPD)
hilb	Depende de ρ_J	Converge (SPD)	Aplica (SPD)
kahan	$\rho = 0$ (triangular)	$\rho = 0$ (triangular)	No aplica (no simétrica)
moler	Depende de ρ_J	Converge (SPD)	Aplica (SPD)

Cuando se menciona "Depende" resolveremos usando el ρ calculado en la Sección 5, donde esta tabla se vuelve a llenar con lo observado. Algunas observaciones sobre la estructura:

Casos especiales

- ▷ **forsythe.** Con $\lambda = 0$ la diagonal es nula, por lo que D^{-1} no existe y ni Jacobi ni Seidel están definidos. Si se permutan las filas, subiendo cada una un lugar (como hizo el pivoteo en la Tarea 1), se obtiene $PA = \text{diag}(\alpha, 1, \dots, 1)$ con $\alpha = \sqrt{\varepsilon_{\text{máq}}}$, que es diagonal, simétrica y definida positiva; entonces los tres métodos quedan definidos y $B_J = B_{GS} = 0$.
- ▷ **kahan.** Es triangular superior, así que $L = 0$ y $B_J = B_{GS} = -D^{-1}U$ es nilpotente: $\rho = 0$ y en teoría el método converge en a lo más n iteraciones. Pero la matriz es muy no normal, por lo que ρ no describe el comportamiento transitorio, y se espera un crecimiento grande del error antes de que caiga.
- ▷ **cauchy, hilb, moler.** Son simétricas definidas positivas, así que Seidel y descenso profundo convergen, pero con κ grande, la razón es $\rho \approx 1 - 2/\kappa$ y hacen falta del orden de κ iteraciones. Por eso se usan tamaños pequeños ($n = 3, \dots, 10$) para medir la tasa y ver cómo $\rho \rightarrow 1$ al crecer n .

4. METODOLOGÍA

4.1 Implementaciones

Los métodos se programaron en Python (3.11.7), dentro de un cuaderno de Jupyter, con NumPy:

- ▷ **Jacobi:** cada componente se calcula solo con la iterada anterior, es decir $\mathbf{x}_{k+1} = (\mathbf{b} - A\mathbf{x}_k + D\mathbf{x}_k) \oslash \text{diag}(A)$.
- ▷ **Seidel:** cada componente usa las componetes ya actualizadas en la misma iteración.
- ▷ **Descenso profundo:** iteración de la 6, con $\mathbf{r}_k = \mathbf{b} - A\mathbf{x}_k$ recalculado en cada paso.

Jacobi y Seidel parten de las versiones del repositorio del curso [Domínguez Mota, 2026], re-escritas para trabajar con vectores y devolver el historial completo. Los tres métodos reciben $(A, \mathbf{b}, \mathbf{x}_0, k_{\text{max}}, \text{tol})$ y devuelven la última iterada, el número de iteraciones y la matriz con todas las iteradas.

Para la teoría, $\rho(B_J)$ y $\rho(B_{GS})$ se calculan con `numpy.linalg.eigvals` sobre las matrices de las Ecs. (3) y (4), y κ con `numpy.linalg.cond`. Como referencia directa se usa `numpy.linalg.solve` (LU con pivoteo parcial), que es el mismo método que se usó para varias matrices en la Tarea 1; en las simétricas definidas positivas, donde allá se usó Cholesky, la diferencia es solo de redondeo.

4.2 Parámetros y criterios de paro

Para cada matriz se toma $\mathbf{b} = A\mathbf{1}_n$ y el punto inicial $\mathbf{x}_0 = \mathbf{0}$, de modo que $\mathbf{r}_0 = \mathbf{b}$. Las iteraciones se detienen cuando se cumple alguna de las condiciones siguientes:

- 1) **Convergencia:** $\|\mathbf{r}_k\| \leq \text{tol} \|\mathbf{r}_0\|$, con $\text{tol} = 10^{-9}$.
- 2) **Máximo de iteraciones:** $k = k_{\text{máx}} = 10^5$.

3) **Divergencia:** $\|\mathbf{r}_k\| \geq 10^{10} \|\mathbf{r}_0\|$.

La tolerancia es la que se usa por defecto en las funciones del curso, y el máximo de iteraciones se fijó de tal forma que puedan converger los casos lentos, por ejemplo, Seidel en `hilb` con $n = 5$ necesita del orden de 10^5 iteraciones. Los casos que no llegan a la tolerancia se definen como **kmax**.

Como en las matrices simétricas definidas positivas mal condicionadas hacen falta del orden de κ iteraciones, los tamaños son pequeños y varían por matriz (Tabla ??). El tamaño de referencia es el que se usa para las figuras y para comparar la solución directa.

Tabla 2. Tamaños usados por matriz.

Matriz	Tamaños n	Referencia
cauchy, chebvand, hilb	3, 4, 5, 6	5
moler	3, 4, 5, 6, 8	5
kahan	10, 20, 30, 40	30
forsythe	10, 30, 50	30

4.3 Procedimiento

Para cada matriz, cada tamaño n y cada método:

- 1) se construye A y $\mathbf{b} = A\mathbf{1}_n$ con las rutinas de la Tarea 1; en `forsythe` se prueba además la versión con las filas permutadas, PA , Y $P\mathbf{b}$;
- 2) se calcula la tasa teórica ($\rho(B_J)$, $\rho(B_{GS})$ o ρ_{DP});
- 3) se itera hasta cumplir un criterio de paro, guardando $\|\mathbf{r}_k\| / \|\mathbf{b}\|$ y $\|\mathbf{e}_k\| / \|\mathbf{x}\|$ en cada paso;
- 4) se estiman la tasa empíricas de las Ecs. (8) y (9) y se compara el número de iteraciones con las predicción de las Ec. (2);
- 5) en el tamaño de referencia, se compara el error final con el método directo de la Tarea 1.

No interviene ningún elemento aleatorio, por lo que los resultados son reproducibles.

4.4 Manejo de fallos

Cada corrida termina en uno de los estados de la Tabla 3.

Tabla 3. Estados posibles de una corrida.

Estado	Significado
<code>converge</code>	se alcanzó la tolerancia
<code>diverge</code>	el residuo creció 10^{10} veces
<code>kmax</code>	se agotaron las iteraciones sin llegar a la tolerancia
<code>no definido</code>	la diagonal tiene ceros (Jacobi y Seidel)
<code>no aplica</code>	A no es simétrica definida positiva (descenso profundo)

Para decidir si A es simétrica definida positiva se comprueba que $A = A^T$ y que todos los valores propios, calculados con `numpy.linalg.eigvalsh`, sean positivos. La tasa $\hat{\rho}_{\text{ajuste}}$ no se calcula cuando en la segunda mitad de las iteraciones hay menos de dos errores positivos.

5. RESULTADOS

Para cada matriz se presenta una tabla con la tasa teórica (ρ), las dos tasas empíricas, el número de iteraciones real (k) y el predicho por la Ec. (2) (k pred.), el estado de la corrida y error relativo final. Cada tabla acompañada de una figura de dos paneles. En las tablas, J = Jacobi, BG = Seidel y **DP** = descenso profundo, y los estados son los de la Tabla 3. AL leerla conviene tener presente que

- ▷ Un valor $\rho \geq 1$ indica divergencia o estancamiento, no un error del programa. En descenso profundo ρ es la cota de la Ec. (7), no un radio espectral.
- ▷ Un error o residuo exactamente cero no puede dibujarse en escala logarítmica, por lo que en las gráficas se representa con 10^{-18} .
- ▷ El error de las tablas es del último paso. En las corridas que divergen es del orden de 10^{10} , porque se detienen cuando el residuo creció 10^{10} veces.

5.1 Aplicabilidad verificada

La Tabla 4 muestra, en el tamaño de referencia de cada matriz, el ρ calculado y lo observado. Coincide con lo esperado por estructura (Tabla 1) y resuelve las celdas "Depende":

- ▷ **Jacobi** diverge en **cauchy** ($\rho_J = 3.659$), **chebvand** (3.715), **hilb** (3.444) y **moler** (1.404). Converge solo en **kahan** y en **forsythe** permutada, donde $\rho = 0$.
- ▷ **Seidel** tiene $\rho_{GS} < 1$ en las tres matrices simétricas definidas positivas (**cauchy**, **hilb**, **moler**), pero en **cauchy** con $n = 5$ no llega a la tolerancia en 10^5 iteraciones ($\rho_{GS} = 0.9999901$). En **chebvand** diverge ($\rho_{GS} = 8.932$).
- ▷ **Descenso profundo** aplica a **cauchy**, **hilb**, **moler** y **forsythe** permutada. No aplica a **chebvand**, **kahan** ni **forsythe** sin permutar.

Tabla 4. Radio espectral calculado y resultado observado, por método y matriz.

matriz	n	Jacobi	Seidel	Descenso profundo
cauchy	5	3.659 (diverge)	0.99999010 (kmax)	0.99999870 (converge)
chebvand	5	3.715 (diverge)	8.932 (diverge)	no aplica
forsythe	30	no definido	no definido	no aplica
forsythe perm	30	0 (converge)	0 (converge)	0.99999997 (converge)
hilb	5	3.444 (diverge)	0.99995767 (converge)	0.99999580 (kmax)
kahan	30	0 (converge)	0 (converge)	no aplica
moler	5	1.404 (diverge)	0.98726920 (converge)	0.99769314 (converge)

5.2 Matriz de Cauchy

Jacobi diverge en todos los tamaños: ρ_J crece de 1.860 ($n = 3$) a 4.549 ($n = 6$). Seidel y descenso profundo tienen $\rho < 1$, pero muy cerca de 1. Con $n = 3$ convergen en 2149 y 5696 iteraciones. Con $n = 4$ Seidel converge en 29331 y descenso profundo llega a **kmax**. Con $n = 5$ ocurre al revés, Seidel llega a **kmax** y descenso profundo converge en 54339. Con $n = 6$ ninguno alcanza la tolerancia. Para $n \leq 5$, $\hat{\rho}_{\text{ajuste}}$ de Seidel coincide con ρ_{GS} en todas las cifras mostradas, con $n = 6$ vale 0.9999917 frente a 0.9999996. En descenso profundo queda por debajo de la cota. El error final crece con n : 9.28×10^{-7} (Seidel, $n = 3$), 3.48×10^{-5} ($n = 4$) y 9.44×10^{-4} (descenso profundo, $n = 5$) (Tabla 5 y Figura 1).

Tabla 5. Resultados para cauchy (Jacobi, Seidel y descenso profundo).

n	método	ρ teórico	$\hat{\rho}_{\text{geom}}$	$\hat{\rho}_{\text{ajuste}}$	k	k pred.	estado	error rel.
3	J	1.86	1.86	1.86	38	—	diverge	1.87×10^{10}
3	GS	0.99431440	0.99040183	0.99431440	2149	3634	converge	9.28×10^{-7}
3	DP	0.99852321	0.99636798	0.99820590	5696	14022	converge	1.11×10^{-6}
4	J	2.763	2.762	2.763	23	—	diverge	1.56×10^{10}
4	GS	0.99975321	0.99929371	0.99975321	29331	83960	converge	3.48×10^{-5}
4	DP	0.99995641	0.99980002	0.99995576	100000	475397	kmax	6.80×10^{-5}
5	J	3.659	3.656	3.659	18	—	diverge	1.54×10^{10}
5	GS	0.99999010	0.99980407	0.99999010	100000	2094288	kmax	3.77×10^{-3}
5	DP	0.99999870	0.99961870	0.99999818	54339	15905561	converge	9.44×10^{-4}
6	J	4.549	4.544	4.549	16	—	diverge	3.80×10^{10}
6	GS	0.99999962	0.99979700	0.99999166	100000	55035244	kmax	2.09×10^{-3}
6	DP	0.99999996	0.99980869	0.99999481	100000	529460408	kmax	1.17×10^{-3}





Figura 1. cauchy: residuo contra k ($n = 5$) y ρ contra n .

5.3 Matriz de Chebyshev–Vandermonde

Ningún método converge. ρ_J está entre 1.611 y 5.379, y ρ_{GS} entre 2.732 y 51.29 ($n = 4$), así que ambos divergen y las corridas se detienen entre 6 y 49 iteraciones. Los valores no son monótonos en n ($\rho_J = 1.6111, 5.379, 3.715, 2.562$ para $n = 3, \dots, 6$). En Seidel, $\hat{\rho}_{\text{ajuste}}$ coincide con ρ_{GS} ; en Jacobi se desvía un poco, porque la corrida dura solo 24 iteraciones. Descenso profundo no aplica, pues la matriz no es simétrica (Tabla 6, Figura 2).

Tabla 6. Resultados para `chebvand` (Jacobi y Seidel).

n	método	ρ teórico	$\hat{\rho}_{\text{geom}}$	$\hat{\rho}_{\text{ajuste}}$	k	k pred.	estado	error rel.
3	J	1.611	1.602	1.609	49	—	diverge	1.24×10^{10}
3	GS	2.732	2.716	2.732	24	—	diverge	2.59×10^{10}
3	DP	—	—	—	—	—	no aplica	—
4	J	5.379	5.357	5.439	14	—	diverge	2.10×10^{10}
4	GS	51.29	48.16	51.29	6	—	diverge	1.59×10^{10}
4	DP	—	—	—	—	—	no aplica	—
5	J	3.715	3.705	3.697	18	—	diverge	1.71×10^{10}
5	GS	8.932	8.786	8.932	11	—	diverge	6.62×10^{10}
5	DP	—	—	—	—	—	no aplica	—
6	J	2.562	2.637	2.455	24	—	diverge	1.34×10^{10}
6	GS	3.417	3.574	3.417	19	—	diverge	1.11×10^{11}
6	DP	—	—	—	—	—	no aplica	—

**Figura 2.** `chebvand`: residuo contra k ($n = 5$) y ρ contra n .

5.4 Matriz de Forsythe

Sin permutar, Jacobi y Seidel no están definidos para ningún n (la diagonal es cero) y descenso profundo no aplica. Con las filas permutadas, $PA = \text{diag}(\alpha, 1, \dots, 1)$ y los tres métodos convergen con error exactamente cero para todos los tamaños: Jacobi y Seidel en 1 iteración ($\rho = 0$) y descenso profundo en 2. En este último la cota $\rho_{\text{DP}} \approx 1 - 3 \times 10^{-8}$ (Tabla 7, Figura 3).


**Figura 3.** `forsythe`: residuo contra k ($n = 30$).

Tabla 7. Resultados para `forsythe`, sin permutar y con filas permutadas (perm.).

n	método	ρ teórico	$\hat{\rho}_{\text{geom}}$	$\hat{\rho}_{\text{ajuste}}$	k	k pred.	estado	error rel.
10	J	—	—	—	—	—	no definido	—
10	GS	—	—	—	—	—	no definido	—
10	DP	—	—	—	—	—	no aplica	—
30	J	—	—	—	—	—	no definido	—
30	GS	—	—	—	—	—	no definido	—
30	DP	—	—	—	—	—	no aplica	—
50	J	—	—	—	—	—	no definido	—
50	GS	—	—	—	—	—	no definido	—
50	DP	—	—	—	—	—	no aplica	—
10	J perm.	0	0	—	1	—	converge	0.00×10^0
10	GS perm.	0	0	—	1	—	converge	0.00×10^0
10	DP perm.	0.99999997	0	—	2	695357414	converge	0.00×10^0
30	J perm.	0	0	—	1	—	converge	0.00×10^0
30	GS perm.	0	0	—	1	—	converge	0.00×10^0
30	DP perm.	0.99999997	0	—	2	695357414	converge	0.00×10^0
50	J perm.	0	0	—	1	—	converge	0.00×10^0
50	GS perm.	0	0	—	1	—	converge	0.00×10^0
50	DP perm.	0.99999997	0	—	2	695357414	converge	0.00×10^0

5.5 Matriz de Hilbert

Jacobi diverge en todos los tamaños (ρ_J de 1.723 a 4.309). Seidel converge en todos, con ρ_{GS} cada vez más cerca de 1 (0.98085893 con $n = 3$, 0.9999983 con $n = 6$) y, 717, 9 213, 94 881 y 39 971 iteraciones para $n = 3, \dots, 6$. El último dato no es monótono en n y es mucho menor que el predicho (12 184 789), pues el criterio de paro usa el residuo y no el error. Descenso profundo converge con $n = 3$ y 4 (2 989 y 53 539 iteraciones) y llega a `kmax` con $n = 5$ y 6. El ajuste de Seidel coincide con ρ_{GS} para $n = 3, 4, 5$ (0.98085893, 0.99902979, 0.9999577). El error final crece de 3.04×10^{-7} a 3.95×10^{-3} al pasar de $n = 3$ a $n = 6$ (Tabla 8, Figura 4).

Tabla 8. Resultados para `hilb` (Jacobi, Seidel y descenso profundo).

n	método	ρ teórico	$\hat{\rho}_{\text{geom}}$	$\hat{\rho}_{\text{ajuste}}$	k	k pred.	estado	error rel.
3	J	1.723	1.722	1.723	43	—	diverge	1.69×10^{10}
3	GS	0.98085893	0.97149633	0.98085893	717	1072	converge	3.04×10^{-7}
3	DP	0.99619089	0.99308985	0.99601712	2989	5430	converge	3.78×10^{-7}
4	J	2.582	2.578	2.582	25	—	diverge	2.38×10^{10}
4	GS	0.99902979	0.99775310	0.99902979	9213	21349	converge	1.06×10^{-5}
4	DP	0.99987109	0.99961300	0.99986959	53539	160748	converge	1.05×10^{-5}
5	J	3.444	3.435	3.444	19	—	diverge	1.94×10^{10}
5	GS	0.99995767	0.99978161	0.99995767	94881	489568	converge	3.48×10^{-4}
5	DP	0.99999580	0.99980864	0.99999573	100000	4938429	kmax	1.37×10^{-3}
6	J	4.309	4.291	4.309	16	—	diverge	1.72×10^{10}
6	GS	0.99999830	0.99948167	0.99999880	39971	12184789	converge	3.95×10^{-3}
6	DP	0.99999987	0.99981661	0.99998553	100000	154917381	kmax	8.78×10^{-4}




Figura 4. hilb: residuo contra k ($n = 5$) y ρ contra n .

5.6 Matriz de Kahan

Jacobi y Seiden producen prácticamente los mismo resultados, como se espera ($L = 0$ y $B_J = B_{GS}$). Con $\rho = 0$ convergen en 10, 19, 26 y 33 iteraciones para $n = 10, 20, 30, 40$, es decir, en a lo mas n . El error final es del orden de 10^{-16} con $n = 10$ y de 10^{-9} en los demás, la corrida se detiene al alcanzar la tolerancia. Sin embargo, el error crece, su pico es 2.23, 23.5, 352 y 5790 veces el error inicial. Las tasas empíricas no son cero y crecen con n ($\hat{\rho}_{\text{geom}} = 0.026, 0.319, 0.441, 0.514$), porque la convergencia es en tiempo finito y no hay régimen asintótico que medir. El panel derecho de la figura muestra $\|B^k\|_2$, que sube varios órdenes de magnitud antes de caer. Descenso profundo no aplica (Tabla 9, Figura 5).

Tabla 9. Resultados para kahan (Jacobi y Seidel).

n	método	ρ teórico	$\hat{\rho}_{\text{geom}}$	$\hat{\rho}_{\text{ajuste}}$	k	k pred.	estado	error rel.	pico del error
10	J	0	0.02431094	0.00319787	10	—	converge	1.40×10^{-16}	2.23×10^0
10	GS	0	0.02570495	0.00333664	10	—	converge	1.89×10^{-16}	2.23×10^0
10	DP	—	—	—	—	—	no aplica	—	—
20	J	0	0.31856614	0.12070421	19	—	converge	9.40×10^{-10}	2.35×10^1
20	GS	0	0.31856613	0.12070420	19	—	converge	9.40×10^{-10}	2.35×10^1
20	DP	—	—	—	—	—	no aplica	—	—
30	J	0	0.44142329	0.17156333	26	—	converge	2.31×10^{-9}	3.52×10^2
30	GS	0	0.44142329	0.17156340	26	—	converge	2.31×10^{-9}	3.52×10^2
30	DP	—	—	—	—	—	no aplica	—	—
40	J	0	0.51384134	0.20955502	33	—	converge	1.48×10^{-9}	5.79×10^3
40	GS	0	0.51384134	0.20955574	33	—	converge	1.48×10^{-9}	5.79×10^3
40	DP	—	—	—	—	—	no aplica	—	—




Figura 5. kahan: residuo contra k ($n = 30$) y $\|B^k\|_2$.

5.7 Matriz de Moler

Jacobi converge solo con $n = 3$ ($\rho_J = 0.9129$, 227 iteraciones, igual a las predichas) y diverge con $n \geq 4$ ($\rho_J = 1.132, 1.404, 1.742, 2.598$). Seidel converge en todos los tamaños, con ρ_{GS} de 0.8333 a 0.9997943 y 104, 349, 1196, 4150 y 48779 iteraciones para $n = 3, 4, 5, 6, 8$; $\hat{\rho}_{ajuste}$ coincide con ρ_{GS} en todos. Descenso profundo converge hasta $n = 6$ (231, 894, 5395 y 23549 iteraciones) y llega a kmax con $n = 8$ ($\rho_{DP} = 0.9999859$), con error final 1.01×10^{-1} . Seidel necesita menos iteraciones que descenso profundo en todos los tamaños (Tabla 10, Figura 6).

Tabla 10. Resultados para moler (Jacobi, Seidel y descenso profundo).

n	método	ρ teórico	$\hat{\rho}_{geom}$	$\hat{\rho}_{ajuste}$	k	k pred.	estado	error rel.
3	J	0.91287093	0.91207268	0.91287093	227	227	converge	1.36×10^{-9}
3	GS	0.83333333	0.81893851	0.83333333	104	114	converge	9.41×10^{-9}
3	DP	0.93395864	0.91418745	0.92412928	231	303	converge	9.72×10^{-9}
4	J	1.132	1.131	1.132	187	—	diverge	7.17×10^9
4	GS	0.95203574	0.94222230	0.95203574	349	422	converge	6.23×10^{-8}
4	DP	0.98705733	0.97705031	0.98191629	894	1591	converge	6.97×10^{-8}
5	J	1.404	1.401	1.404	69	—	diverge	1.13×10^{10}
5	GS	0.98726920	0.98281560	0.98726920	1196	1617	converge	4.07×10^{-7}
5	DP	0.99769314	0.99616590	0.99734303	5395	8973	converge	4.49×10^{-7}
6	J	1.742	1.737	1.742	42	—	diverge	1.18×10^{10}
6	GS	0.99674369	0.99501830	0.99674369	4150	6354	converge	2.45×10^{-6}
6	DP	0.99959011	0.99912035	0.99947337	23549	50548	converge	2.89×10^{-6}
8	J	2.598	2.593	2.598	25	—	diverge	2.32×10^{10}
8	GS	0.99979427	0.99957525	0.99979427	48779	100719	converge	7.70×10^{-5}
8	DP	0.99998591	0.99986774	0.99998195	100000	1471175	kmax	1.01×10^{-1}




Figura 6. `moler`: residuo contra k ($n = 5$) y ρ contra n .

5.8 Comparación con la solución directa

La Tabla 11 compara, en el tamaño de referencia ($n = 5$ en `cauchy`, `chebvand`, `hilb` y `moler`; $n = 30$ en `forsythe` y `kahan`), el error del método directo (`numpy.linalg.solve`) con el de cada método iterativo. En las matrices simétricas definidas positivas el directo es mucho más exacto: en `hilb` 1.26×10^{-12} frente a 3.48×10^{-4} (Seidel), en `cauchy` 2.03×10^{-11} frente a 9.44×10^{-4} (descenso profundo), y en `moler` 0 frente a 4.07×10^{-7} (Seidel). En esos casos el error iterativo es del orden de $\kappa \cdot \text{tol}$ ($\kappa = 4.77 \times 10^5$, 1.54×10^6 y 8.66×10^2), detenerse con residuo $\leq 10^{-9}$ no garantiza un error pequeño. En `kahan` ambos son pequeños (3.64×10^{-15} directo, 2.31×10^{-9} iterativo) y en `forsythe` permutada los tres métodos dan error cero. En `chebvand` no converge ningún iterativo, aunque el directo da 1.23×10^{-14} .

Tabla 11. Comparación de los métodos iterativos con el método directo en el tamaño de referencia.

matriz	n	cond(A)	directo	Jacobi	Seidel	Descenso profundo
<code>cauchy</code>	5	1.54×10^6	1.73×10^{-11}	diverge	3.77×10^{-3} (kmax)	9.44×10^{-4}
<code>chebvand</code>	5	5.68×10^2	0.00×10^0	diverge	diverge	no aplica
<code>forsythe perm</code>	30	6.71×10^7	0.00×10^0	0.00×10^0	0.00×10^0	0.00×10^0
<code>hilb</code>	5	4.77×10^5	3.78×10^{-12}	diverge	3.48×10^{-4}	1.37×10^{-3} (kmax)
<code>kahan</code>	30	1.40×10^5	1.48×10^{-14}	2.31×10^{-9}	2.31×10^{-9}	no aplica
<code>moler</code>	5	8.66×10^2	0.00×10^0	diverge	4.07×10^{-7}	4.49×10^{-7}

6. ANÁLISIS

6.1 Tasa teórica frente a tasa empírica

Para Jacobi y Seidel, $\hat{\rho}_{\text{ajuste}}$ reproduce $\rho(B)$ con mucha precisión. En las 34 corridas con $\rho > 0$ y ajuste definido, la diferencia relativa máxima es de 4.2% (Jacobi en `chebvand` con $n = 6$, que dura solo 24 iteraciones), y en las 15 corridas con al menos 100 iteraciones es menor que 8×10^{-6} . Esto verifica la Ec. (5), incluso cuando $\rho > 1$ y el método diverge, pues la tasa asintótica es la misma en ambos sentidos.

En descenso profundo, ρ_{DP} es una cota y no un radio espectral. En las 13 corridas con $\rho_{\text{DP}} < 1$ y ajuste definido, $\hat{\rho}_{\text{ajuste}}$ queda por debajo de la cota, y la diferencia va de 8×10^{-8} (`hilb`, $n = 5$) a 9.8×10^{-3} (`moler`, $n = 3$), de modo que la cota describe bien la tasa observada.

La tasa geométrica $\hat{\rho}_{\text{geom}}$ es peor estimador cuando $\rho \approx 1$. Incluye el transitorio inicial, donde el

residuo baja rápido por los modos rápidos, y por eso aparenta una convergencia más veloz que la real, en `hilb` con $n = 5$ y Seidel, $1 - \hat{\rho}_{\text{geom}} = 2.2 \times 10^{-4}$ frente a $1 - \rho_{GS} = 4.2 \times 10^{-5}$, unas cinco veces mayor. Por eso la comparación con la teoría se hace con $\hat{\rho}_{\text{ajuste}}$.

El número de iteraciones predicho por la Ec. (2) sobreestima el real en todos los casos simétricos definidos positivos que convergen: coincide en Jacobi sobre `moler` con $n = 3$ (227 iteraciones) y en los demás el predicho es entre 1.1 y 305 veces mayor (por ejemplo, 39 971 reales frente a 12 184 789 predichas en `hilb` con $n = 6$, Seidel). La razón es que el paro se hace sobre el residuo, que puede ser mucho menor que el error (Sección 6.4). En `forsythe` permutada la cota de descenso profundo ($\rho_{DP} \approx 1 - 3 \times 10^{-8}$) predice del orden de 7×10^8 iteraciones y bastan 2, porque PA solo tiene dos valores propios distintos (α y 1) y la componente asociada a α pesa muy poco en el residuo inicial.

6.2 Jacobi frente a Seidel

Cuando A estás consistentemente ordenada se cumple $\rho_{GS} = \rho_J^2$, y Seidel necesita la mitad de iteraciones. En el ejemplo 2×2 de validación del notebook se cumple ($0.2222 = 0.4714^2$), pero en estas matrices ocurre solo en `moler` con $n = 3$, donde ambos valen 0.8333 y las iteraciones pasan de 227 (Jacobi) a 104 (Seidel). En las demás no hay relación simple, en `hilb` con $n = 3$, $\rho_J^2 = 2.969$ y $\rho_{GS} = 0.981$; en `chebvand` con $n = 3$, $\rho_J^2 = 2.594$ y $\rho_{GS} = 2.732$.

En consecuencia, ninguno de los dos domina al otro en general:

- ▷ En las tres matrices simétricas definidas positivas Seidel converge ($\rho_{GS} < 1$) donde Jacobi diverge: `cauchy` y `hilb` en todos los tamaños, y `moler` con $n \geq 4$.
- ▷ En `chebvand` ocurre lo contrario: $\rho_{GS} > \rho_J$ en los cuatro tamaños (por ejemplo, 51.29 frente a 5.379 con $n = 4$), y ambos divergen.
- ▷ En `kahan`, $L = 0$ y los dos métodos son idénticos ($B_J = B_{GS}$).

Frente a descenso profundo, Seidel necesita menos iteraciones en `moler` y en `hilb` en todos los tamaños que convergen, y el cociente crece con n : en `moler`, descenso profundo usa 2.2, 2.6, 4.5 y 5.7 veces las iteraciones de Seidel para $n = 3, 4, 5, 6$. La excepción es `cauchy` con $n = 5$, donde descenso profundo converge (54 339 iteraciones) y Seidel no llega a la tolerancia en 10^5 ; el número de iteraciones depende también del criterio de paro y de cuánto pesan los modos lentos en el residuo, por lo que no es monótono en n .

6.3 Efecto del condicionamiento

En las matrices simétricas definidas positivas el mal condicionamiento determina la velocidad. Para descenso profundo, $1 - \rho_{DP} \approx 2/\kappa$ con una diferencia de a lo más 4% en todos los casos (por ejemplo, 4.196×10^{-6} en ambos lados con `hilb` y $n = 5$). Seidel se comporta de forma parecida, $1 - \rho_{GS} \approx c/\kappa$, con c entre 4.9 y 29 en estos casos y creciendo lentamente con n , de modo que Seidel gana a la cota de descenso profundo por un factor entre 2.5 y 14.6 y el número de iteraciones es del orden de κ/c .

Además, κ crece exponencialmente con n : unas 31 veces por cada incremento de n en `hilb` ($5.2 \times 10^2, 1.6 \times 10^4, 4.8 \times 10^5, 1.5 \times 10^7$ para $n = 3, \dots, 6$), unas 34 en `cauchy` y unas 5 en `moler`, en línea con lo observado en la Tarea 1. Por eso $\rho \rightarrow 1$ al crecer n (Figuras 1, 4 y 6), y las iteraciones de Seidel en `hilb` pasan de 717 a 9 213 y a 94 881 para $n = 3, 4, 5$, es decir, $\times 12.8$ y $\times 10.3$ (menos que κ porque c también crece). Con $n = 6$ usa menos iteraciones (39 971), pero se detiene con un

error mayor (3.95×10^{-3} frente a 3.48×10^{-4}), de modo que el criterio de residuo deja de ser una buena señal de la calidad de la solución.

Esto conecta con la Tarea 1, el mismo κ que hacía que los métodos directos perdieran cifras (`hilb` con $n = 10$ tiene $\kappa = 1.6 \times 10^{13}$) aquí hace inviable la iteración, pues la cota de descenso profundo, $k \approx (\kappa/2) \ln(1/\text{tol})$, daría del orden de 10^{14} iteraciones.

6.4 Residuo frente a error

Como en la Tarea 1, el error relativo cumple

$$\frac{\|\mathbf{x}_k - \mathbf{x}\|}{\|\mathbf{x}\|} \leq \text{cond}(A) \frac{\|\mathbf{r}_k\|}{\|\mathbf{b}\|}, \quad (10)$$

así que detenerse con residuo $\leq 10^{-9}$ solo garantiza un error pequeño si $\text{cond}(A)$ es moderado. En las matrices simétricas definidas positivas la cota se aprovecha casi por completo, con $n = 5$, el error final es 3.48×10^{-4} en `hilb` (Seidel), 9.44×10^{-4} en `cauchy` (descenso profundo) y 4.07×10^{-7} en `moler` (Seidel), entre el 47 % y el 73 % de $\text{cond}(A) \cdot \text{tol}$ (4.77×10^{-4} , 1.54×10^{-3} y 8.66×10^{-7}). El método directo, en cambio, da 1.26×10^{-12} , 2.03×10^{-11} y 0 (Tabla 11), con la misma κ , el directo es hasta 10^8 veces más exacto. En `kahan` la cota es muy holgada (2.31×10^{-9} frente a 1.4×10^{-4}), porque la convergencia es finita.

6.5 El caso de Kahan: radio espectral y no normalidad

En `kahan`, $B_J = B_{GS} = -D^{-1}U$ es nilpotente, así que $\rho = 0$ y el método termina en a lo más n iteraciones, lo cual se observa (10, 19, 26 y 33 iteraciones para $n = 10, 20, 30, 40$). Pero $\rho = 0$ no dice nada del transitorio: B_J es muy no normal, con $\|B_J\|_2 = 2.19, 4.50, 6.81$ y 9.11 (una matriz normal tendría $\|B_J\|_2 = \rho = 0$), y el error llega a multiplicarse por 2.23, 23.5, 352 y 5790 antes de caer, aproximadamente $\times 10$ a $\times 16$ por cada 10 unidades de n . Las tasas empíricas tampoco se acercan a 0 ($\hat{\rho}_{\text{geom}} = 0.026, 0.319, 0.441, 0.514$) porque promedian el transitorio. El panel derecho de la Figura 5 muestra $\|B^k\|_2$, que sube varios órdenes de magnitud antes de anularse en $k = n$. Es la ilustración de que $\rho(B)$ describe el comportamiento asintótico (Sección 2.2), pero no el tramo inicial, que aquí es todo el método.

6.6 Cuándo conviene un método iterativo

Cada iteración de los tres métodos cuesta $O(n^2)$ (un producto matriz-vector), mientras que un método directo cuesta $\frac{2}{3}n^3$ (LU) o $\frac{1}{3}n^3$ (Cholesky). Un iterativo compite si $k \ll n$, y en estos experimentos casi nunca ocurre: con $n = 5$, Seidel en `hilb` usa 94881 iteraciones, del orden de 10^7 operaciones frente a unas 10^2 del LU. Incluso en `kahan`, donde converge en unas n iteraciones, el costo total es $O(n^3)$, peor que la sustitución hacia atrás ($O(n^2)$) con que se resolvió en la Tarea 1. En `forsythe`, la permutación de filas que hace posibles Jacobi y Seidel es el mismo recurso que el pivoteo de la Tarea 1, y deja un sistema diagonal que cualquier método resuelve en una o dos iteraciones.

Los métodos iterativos suelen ser ventajosos con matrices ralas y grandes y κ moderado, donde cada iteración es barata y $k \ll n$. Ninguna de las seis matrices cumple esas condiciones: salvo `forsythe`, son densas, y las simétricas definidas positivas tienen κ tan grande que $k \sim \kappa$. Para este tipo de problemas, los métodos directos de la Tarea 1 son preferibles.

7. CONCLUSIONES

Conclusiones principales

- 1) **La velocidad de convergencia la fija $\rho(B)$ en Jacobi y Seidel, y κ en descenso profundo, y la teoría se verificó.** En las 34 corridas de Jacobi y Seidel con $\rho > 0$, la tasa medida difiere de $\rho(B)$ a lo más en 4.2% (con pocas iteraciones) y en menos de 8×10^{-6} con 100 iteraciones o más, incluso cuando $\rho > 1$ y el método diverge. En descenso profundo la tasa medida queda siempre por debajo de la cota, y $1 - \rho_{DP} \approx 2/\kappa$ con una diferencia de a lo más 4%.
- 2) **Qué método converge depende de la estructura de la matriz.** Jacobi diverge en `cauchy`, `hilb` y `chebvand` (todos los n probados) y en `moler` con $n \geq 4$, mientras que Seidel tiene $\rho_{GS} < 1$ en las tres matrices simétricas definidas positivas; en `chebvand` ningún método converge. `forsythe` no admite Jacobi ni Seidel por su diagonal nula, pero con las filas permutadas ($PA = \text{diag}(\alpha, 1, \dots, 1)$) los tres métodos convergen en 1 o 2 iteraciones. Jacobi y Seidel no son comparables en general: $\rho_{GS} = \rho_J^2$ solo se observó en `moler` con $n = 3$.
- 3) **El mal condicionamiento hace que $\rho \rightarrow 1$ y vuelve inviable la iteración.** En `hilb`, κ crece unas 31 veces por cada incremento de n y las iteraciones de Seidel pasan de 717 a 9213 y a 94881 para $n = 3, 4, 5$. Con $n = 10$ (`hilb`, $\kappa = 1.6 \times 10^{13}$) la cota de descenso profundo daría del orden de 10^{14} iteraciones. Las matrices que habían perdido todas las cifras con los métodos directos son las mismas que aquí exigen del orden de κ iteraciones.
- 4) **Un residuo pequeño no garantiza un error pequeño, y los métodos directos resultan preferibles.** Con residuo $\leq 10^{-9}$, el error final es entre el 47% y el 73% de $\text{cond}(A) \cdot 10^{-9}$ en `hilb`, `cauchy` y `moler` (3.48×10^{-4} , 9.44×10^{-4} y 4.07×10^{-7} con $n = 5$), hasta 10^8 veces mayor que el del directo (1.26×10^{-12} en `hilb`). Además, cada iteración cuesta $O(n^2)$ y aquí se necesitan muchas más de n ; ninguna de las seis matrices cumple las condiciones en que los iterativos compensan (matrices ralas, κ moderado).
- 5) **$\rho(B)$ solo describe el comportamiento asintótico.** En `kahan`, $B_J = B_{GS}$ es nilpotente y $\rho = 0$, de modo que el método termina en a lo sumo n iteraciones (10, 19, 26 y 33 para $n = 10, 20, 30, 40$); sin embargo, la matriz es muy no normal ($\|B_J\|_2$ llega a 9.11 con $n = 40$) y el error se multiplica por 5 790 antes de caer. Las tasas empíricas (0.026 a 0.514) tampoco coinciden con $\rho = 0$, porque promedian ese transitorio.

A. CÓDIGO

El código completo, junto con el notebook que genera las tablas y figuras, está en [Cano-Villegas, 2026]. Aquí se incluyen los métodos iterativos; el experimento (tasas teóricas y empíricas, tablas y figuras) está en el notebook.

A.1 Métodos iterativos

Listing 1. iterativos.py: Jacobi, Seidel y descenso profundo.

```

1  """
2  iterativos.py -- Jacobi, Seidel y Descenso profundo.
3
4  Los tres reciben (A, b, x0, kmax, tol) y devuelven (x, k, X):
5  x: última iterada
6  k: número de iteraciones realizadas
7  X: arreglo (k+1) x n con todas las iteradas (X[0] = x0)
8
9  Criterios de paro: ||r_k|| ≤ tol * ||r_0||, k = kmax, o divergencia (||r_k|| ≥ 1e10 * ||r_0||).
10 """
11 import numpy as np
12
13
14 def jacobi(A, b, x0, kmax, tol=1e-9):
15     # Cada componente usa solo la iterada anterior: x_new = (b - (L+U) x) / d
16     d = np.diag(A)
17     x = x0.copy()
18     r = b - A @ x
19     r0 = np.linalg.norm(r)
20     X = [x]
21     k = 0
22     while tol * r0 < np.linalg.norm(r) < 1e10 * r0 and k < kmax:
23         x = (b - A @ x + d * x) / d          # A @ x - d * x = (L+U) x
24         r = b - A @ x
25         X.append(x)
26         k += 1
27     return x, k, np.array(X)
28
29
30 def seidel(A, b, x0, kmax, tol=1e-9):
31     # Cada componente usa ya las componentes nuevas de esta misma iteracion.
32     n = len(b)
33     x = x0.copy()
34     r = b - A @ x
35     r0 = np.linalg.norm(r)
36     X = [x.copy()]
37     k = 0
38     while tol * r0 < np.linalg.norm(r) < 1e10 * r0 and k < kmax:
39         for i in range(n):
40             x[i] = (b[i] - A[i, :i] @ x[:i] - A[i, i+1:] @ x[i+1:]) / A[i, i]
41         r = b - A @ x
42         X.append(x.copy())
43         k += 1
44     return x, k, np.array(X)
45
46

```

```
47 def descenso(A, b, x0, kmax, tol=1e-9):
48     # Avanza en la direccion del residuo con el paso que minimiza la energia.
49     x = x0.copy()
50     r = b - A @ x
51     r0 = np.linalg.norm(r)
52     X = [x]
53     k = 0
54     while tol * r0 < np.linalg.norm(r) < 1e10 * r0 and k < kmax:
55         alpha = (r @ r) / (r @ (A @ r))
56         x = x + alpha * r
57         r = b - A @ x
58         X.append(x)
59         k += 1
60     return x, k, np.array(X)
```

REFERENCIAS

- Raúl Cano-Villegas. Métodos numéricos: tareas, código y reportes. https://github.com/RaulCanoVillegas/Numerical_methods_by_lmMobs.git, 2026.
- Francisco J. Domínguez Mota. Métodos numéricos: repositorio del curso. <https://github.com/dmota-at-umich/MN.git>, 2026.
- Nicholas J. Higham. Algorithm 694: A collection of test matrices in matlab. *ACM Transactions on Mathematical Software*, 17(3):289–305, 1991.